جلسهٔ ۴ — نویز و بازسازیِ تصویر

جزوهٔ درس — هفتهٔ چهارم

مکملِ اسلایدهای انگلیسیِ جلسهٔ ۴. تصاویر از دیتاستِ واقعیِ شما (پلاک) تولید شده‌اند. هدف: مدل‌کردنِ نویز و حذفِ آن بدونِ نابودیِ جزئیاتِ لازم.

فهرست مطالب

۱ چرا این جلسه ۱

۱.۱ بازسازی، یک مسئلهٔ معکوس است ۱

۲ مدل‌های نویز ۲

۱.۲ دو نویزی که باید بشناسید ۲

۲.۲ تولیدِ نویزِ مصنوعی برای آزمایش ۲

۳.۲ تشخیصِ نویز ۳

۳ بازسازی (Restoration) ۳

۱.۳ حذفِ نویزِ گاوسی ۳

۲.۳ حذفِ نمک‌وفلفل — میانه برنده است ۳

۳.۳ دوطرفه و میانگینِ ناموضعی ۴

۴ انواعِ بیشترِ نویز ۴

۵ مثالِ عددیِ PSNR ۵

۶ تمرینِ کلاسیِ وسط‌جلسه (۱۰ دقیقه) ۵

۷ راهبردِ حذفِ نویز در عمل ۵

۱.۷ ترتیب در خطِ لوله ۶

۸ بخشِ عمیق ۶

۱.۸ اندازه‌گیریِ بازسازی: PSNR و SSIM ۶

۲.۸ معضلِ حذفِ نویز ۷

۳.۸ بازسازی در برابرِ بهبود ۷

۴.۸ رفعِ تاری و PSF ۷

۹ حذفِ نویزِ زمانی و یادگیریِ عمیق ۷

۱.۹ میانگین‌گیریِ چند فریم ۷

۲.۹ ریاضیِ میانگین‌گیریِ فریم‌ها ۷

۳.۹ نسبتِ سیگنال به نویز (SNR) ۸

۴.۹ حذف‌کننده‌های یادگیریِ عمیق (پیش‌درآمد) ۸

۱۰ کور در برابرِ غیرکور ۸

۱۱ این جلسه در پروژهٔ نهایی ۹

۱۲ جمع‌بندی ۹

۱ چرا این جلسه

عکس‌های واقعیِ کنتور نویزی‌اند (نورِ کم، ISOی بالا). حذفِ نویز همان چیزی است که ارقام را آستانه‌پذیر و خوانا می‌کند. اما هر حذفِ نویز یک مبادله است: زیادی‌اش، ارقام را پاک می‌کند. امروز یاد می‌گیریم نویز از کجا می‌آید، چطور مدلش کنیم، و چطور حذفش کنیم.

نکتهٔ کلیدی

اصلِ کلیدیِ این جلسه: نوعِ نویز، درمانِ آن را تعیین می‌کند. نویزِ گاوسی → میانگین‌گیری؛ نویزِ ضربه‌ای → میانه. اول تشخیص، بعد درمان. استفاده از فیلترِ اشتباه، جزئیات را هدر می‌دهد یا اصلاً پاک نمی‌کند.

۱.۱ بازسازی، یک مسئلهٔ معکوس است

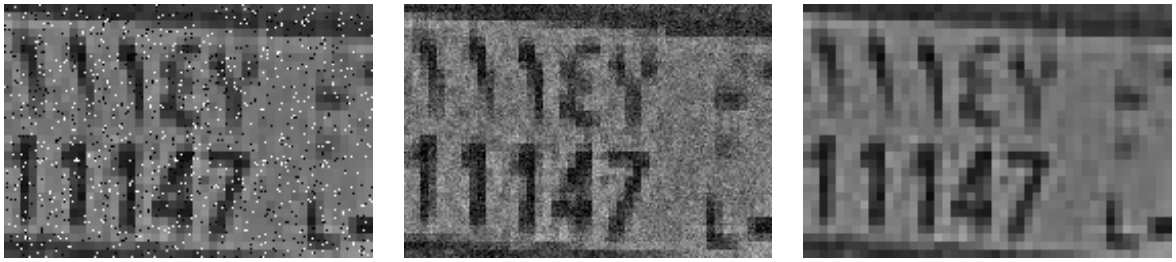
بازسازی یک **مسئلهٔ معکوس** است: تصویرِ اصلی f توسطِ یک فرایندِ تخریب (نویز، تاری) به تصویرِ مشاهده‌شدهٔ g تبدیل شده، و ما می‌خواهیم f را بازیابی کنیم. صوری: $g = H(f) + n$ که H تخریب (مثلِ تاری) و n نویز است. اگر H و آمارِ نویز را بشناسیم، می‌توانیم بهترین تخمینِ f را بزنیم.

نکتهٔ کلیدی

چرا این «معکوس» سخت است؟ چون اطلاعات از دست رفته و چند fی مختلف می‌توانند همان g را بدهند. برای همین بازسازی همیشه به فرض‌ها یا «منظم‌سازی» (regularization) نیاز دارد — مثلاً «تصویرِ واقعی احتمالاً نرم است». این ایده در کلِ پردازش تصویر و یادگیریِ عمیق تکرار می‌شود.

۲ مدل‌های نویز

۱.۲ دو نویزی که باید بشناسید



چپ: تمیز — وسط: نویزِ گاوسی — راست: نمک‌وفلفل (ضربه‌ای)

- **نویزِ گاوسی**: نوساناتِ تصادفیِ کوچک که به هر پیکسل اضافه می‌شود (نویزِ حسگر/خواندن).
- **نمک‌وفلفل** (ضربه‌ای): پیکسل‌های تصادفیِ گیرکرده روی ۰ یا ۲۵۵ (پیکسلِ مرده، انتقال).
- **پواسون** (شات): از شمارشِ فوتون؛ در نواحیِ تاریک/نورِ کم قوی‌تر.

ریاضیات

مدلِ گاوسی: $g = f + n$ با $n \sim \mathcal{N}(0, \sigma^2)$ — جمعی و میانگین‌صفر. یعنی هر پیکسلِ مشاهده‌شده = پیکسلِ واقعی + یک مقدارِ تصادفیِ کوچک.

۲.۲ تولیدِ نویزِ مصنوعی برای آزمایش

برای فهمِ نویز، بهترین راه ساختنِ آن است. با یک تصویرِ تمیز شروع کنید و نویزِ معلوم اضافه کنید — حالا «حقیقتِ زمینه» دارید و می‌توانید هر حذف‌کننده را عینی بسنجید:

```python
def add_gaussian(img, sigma=20):
    noise = np.random.normal(0, sigma, img.shape)
    return np.clip(img.astype(np.float32) + noise, 0, 255).astype(np.uint8)

def add_salt_pepper(img, p(06.0=:
    out = img.copy()
    out[np.random.rand(*img.shape) < p/2] = 255    # salt
    out[np.random.rand(*img.shape) < p/2] = 0      # pepper
    return out
```

یادداشت

این یک تکنیکِ آزمایشیِ کلیدی در پردازش تصویر است: چون معمولاً «تصویرِ واقعیِ بدونِ نویز» را نداریم، با افزودنِ نویزِ مصنوعی به یک تصویرِ تمیز، یک آزمایشِ کنترل‌شده می‌سازیم. همان کاری که برای تولیدِ شکل‌های این جلسه کردیم.

۳.۲ تشخیصِ نویز

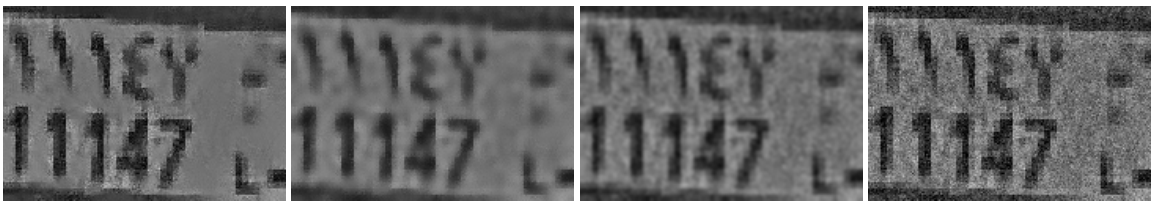
به یک ناحیهٔ **تخت** نگاه کنید: گاوسی = یک پخشِ محو؛ نمک‌وفلفل = لکه‌های سیاه/سفیدِ منزوی. هیستوگرامِ یک وصلهٔ تخت: گاوسی قله را پهن می‌کند؛ ضربه‌ای پیک‌هایی در ۰ و ۲۵۵ اضافه می‌کند. فیلتر را با آنچه می‌بینید تطبیق دهید.

هشدار / دام

میانگین‌گیری (تاریِ گاوسی) به‌سختی نمک‌وفلفل را لمس می‌کند — فقط هر لکه را به یک لکهٔ خاکستری پخش می‌کند. استفاده از فیلترِ اشتباه، بدترین حالت است: هم نویز می‌ماند و هم جزئیات از دست می‌رود.

۳ بازسازی (Restoration)

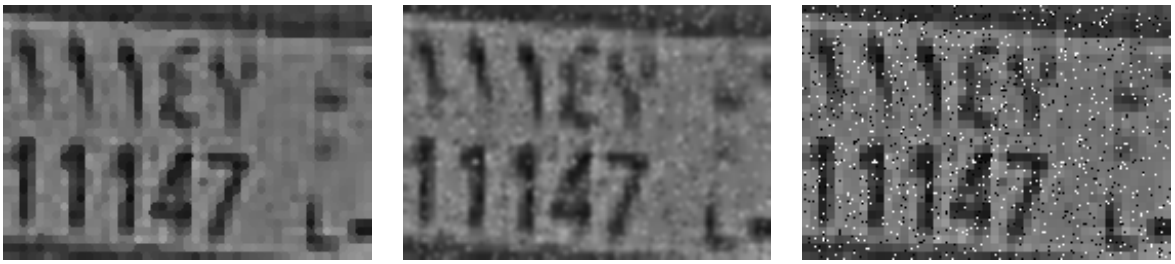
۱.۳ حذفِ نویزِ گاوسی



نویزی — تاریِ گاوسی — دوطرفه — میانگینِ ناموضعی (NLM)

تاریِ گاوسی هموار می‌کند اما لبه‌ها را می‌مالد؛ دوطرفه لبه‌ها را حفظ می‌کند؛ NLM بهترین است اما کندترین.

۲.۳ حذفِ نمک‌وفلفل — میانه برنده است



نویزی — گاوسی (بد) — میانه (عالی)

ریاضیات

میانگینِ $\{۱۰۰, ۱۰۰, ۱۰۰, ۲۵۵\} = ۱۶۴$ — پرت‌داده آن را بالا می‌کشد. میانهٔ همان $= ۱۰۰$ — پرت‌داده کاملاً نادیده گرفته می‌شود. میانگین‌گیری یک ضربه را پخش می‌کند؛ میانه آن را حذف می‌کند.

نکتهٔ کلیدی

میانه در برابرِ پرت‌داده‌ها مقاوم است؛ میانگین نیست. همین یک واقعیت، کلِ نتیجه را توضیح می‌دهد: یک لکهٔ ۲۵۵ در میانِ ۱۰۰ها، میانه را تکان نمی‌دهد، پس میانه ضربه را می‌کشد و لبه‌ها را نگه می‌دارد.

۳.۳ دوطرفه و میانگینِ ناموضعی

- **دوطرفه** (bilateral): فقط همسایه‌های هم‌شدت را میانگین می‌گیرد → هموارکردنِ تخت‌ها، حفظِ لبه.
- **میانگینِ ناموضعی** (NLM): پیکسل‌هایی با الگوی همسایگیِ مشابه را — هرجای تصویر — میانگین می‌گیرد.

NLM بهترین کیفیت را روی نویزِ گاوسی می‌دهد، به قیمتِ سرعت. برای DocScan: دوطرفه یا NLM پیش از آستانه‌گذاری، لبه‌های رقم را تیز نگه می‌دارد در حالی که دانه‌بندیِ حسگر را می‌کشد.

۴ انواعِ بیشترِ نویز

فراتر از دو نویزِ اصلی، چند نوعِ دیگر که در عمل می‌بینید:

نویز	منشأ و درمان
پواسون (شات)	شمارشِ فوتون؛ در نورِ کم بدتر؛ NLM یا پایدارسازیِ واریانس
کوانتش	از عمقِ بیتِ پایین (نوارنوارشدن)؛ dithering
دوره‌ای	الگوی تکرارشونده (تداخلِ الکتریکی، اسکن)؛ حوزهٔ فرکانس (جلسهٔ ۶)
لکه‌ای (speckle)	ضربی، در راداری/سونوگرافی؛ فیلترهای ویژه

نکتهٔ کلیدی

نویزِ **دوره‌ای** برای فیلترهای مکانی نامرئی است — یک الگوی موجیِ منظم را نمی‌توان با میانگین‌گیریِ محلی حذف کرد، چون در همه‌جا هست. آن را در حوزهٔ فرکانس (جلسهٔ ۶) حذف می‌کنیم، جایی که به‌صورتِ چند نقطهٔ روشن ظاهر می‌شود و می‌توان دقیقاً حذفشان کرد.

۵ مثالِ عددیِ PSNR

بیایید PSNR را دستی حساب کنیم تا معنایش روشن شود. فرض کنید دو تصویرِ کوچک داریم که تفاوتشان در میانگینِ مربعاتِ خطا (MSE) برابرِ ۲۵ است (یعنی به‌طورِ متوسط هر پیکسل ۵ واحد خطا دارد):

$$\mathrm{PSNR} = ۱۰ \log_{۱۰} \frac{۲۵۵^۲}{۲۵} = ۱۰ \log_{۱۰}(۲۶۰۱) \approx ۳۴٫۲\,\mathrm{dB}$$

تفسیر: PSNR بالای ۳۰ dB معمولاً کیفیتِ خوب، و بالای ۴۰ dB عالی است. اگر یک حذف‌کنندهٔ نویز PSNR را از ۲۵ به ۳۴ dB ببرد، بهبودِ چشمگیری داده. اما دقت کنید: PSNR فقط خطای پیکسلی را می‌سنجد؛ یک تصویرِ کمی تارِ اما «تمیز» ممکن است PSNR خوب بگیرد در حالی که ارقام خوانا نیستند — برای همین SSIM یا دقتِ OCR نهایی سنجهٔ بهتری‌اند.

یادداشت

درسِ کلی: هیچ سنجهٔ واحدی کامل نیست. PSNR ساده و رایج است، SSIM ادراکی‌تر، و بهترین سنجه اغلب **عملکردِ پایین‌دستی** است (آیا OCR بهتر شد؟). برای پروژه، هر سه را در نظر بگیرید.

۶ تمرینِ کلاسیِ وسط‌جلسه (۱۰ دقیقه)

تمرین

برای هر وضعیت، کدام فیلتر و چرا؟ (۱) یک کنتورِ اسکن‌شده با نقاطِ سیاه/سفیدِ تصادفی. (۲) یک عکسِ موبایلیِ کم‌نور با دانه‌بندیِ ریز در همه‌جا. (۳) سندی که باید لبه‌های متن تیغه‌ای بماند در حالی که دانه حذف می‌شود. (۴) چطور اندازه می‌گیرید که حذفِ نویزتان واقعاً کمک کرد؟

جمع‌بندی: (۱) نمک‌وفلفل → **میانه**. (۲) دانهٔ گاوسی → گاوسی/NLM. (۳) حفظِ لبه → **دوطرفه** (یا NLM). (۴) با PSNR/SSIM در برابرِ مرجعِ تمیز، یا با دقتِ OCR نهایی. قاعدهٔ طلایی: **ارزان‌ترین** فیلتری که نویزِ موردِ اهمیتِ خطِ لولهٔ شما را حذف کند.

۷ راهبردِ حذفِ نویز در عمل

انتخابِ فیلتر تنها بخشِ ماجرا نیست؛ یک راهبردِ کامل:

۱. **تشخیص**: به یک ناحیهٔ تخت نگاه کنید و هیستوگرامش را ببینید. گاوسی است یا ضربه‌ای؟

۲. **انتخابِ فیلتر**: میانه برای ضربه، گاوسی/دوطرفه/NLM برای گاوسی.

۳. **تنظیمِ قدرت**: از ضعیف شروع کنید و زیاد کنید تا نویز کافی حذف شود — نه بیشتر.

۴. **اندازه‌گیری**: PSNR (اگر مرجع دارید) یا اثر بر گامِ بعدی (کیفیتِ آستانه).

۵. **تکرار روی موارد سخت**: پارامترها را روی نویزی‌ترین تصاویر تنظیم کنید، نه تمیزترین.

```
# a small experiment: add known noise, denoise, measure
clean = cv2.imread('meter.png', 0)
noisy = add_gaussian(clean, sigma=20)
for f in [cv2.medianBlur, gaussian, bilateral, nlm]:
    out = f(noisy)
    print(f.__name__, psnr(clean, out))   # pick the winner objectively
```

۱.۷ ترتیب در خطِ لوله

جایگاهِ حذفِ نویز در خطِ لوله مهم است: زود (پس از خاکستری‌سازی، پیش از بهبود و آستانه). چرا؟ چون بهبودِ کنتراست (جلسهٔ ۲) نویز را تقویت می‌کند، پس اگر اول بهبود دهید و بعد حذفِ نویز کنید، کارتان سخت‌تر است. و آستانه‌گذاری روی تصویرِ نویزی، لکه‌های سیاه/سفیدِ فراوان می‌سازد.

نکتهٔ کلیدی

اما یک استثنا: اگر نویز خیلی کم است، حذفِ نویز ممکن است جزئیاتِ بیشتری از نویز بگیرد. همیشه بپرسید «آیا واقعاً به حذفِ نویز نیاز دارم؟» — گاهی بهترین حذفِ نویز، هیچ‌حذفِ‌نویز است.

۸ بخشِ عمیق

۱.۸ اندازه‌گیریِ بازسازی: PSNR و SSIM

- **PSNR**: بر اساسِ خطای میانگینِ مربعات در برابرِ مرجعِ تمیز؛ بالاتر = نزدیک‌تر (بر حسبِ دسی‌بل).
- **SSIM**: ادراکی — ساختار را مقایسه می‌کند، نه فقط خطای پیکسلی؛ با قضاوتِ انسان بهتر می‌خواند.

ریاضیات

$\mathrm{PSNR} = ۱۰ \log_{۱۰} \frac{۲۵۵^۲}{\mathrm{MSE}}$ که در آن MSE میانگینِ مربعِ تفاوتِ دو تصویر است.

اگر مرجعِ تمیز دارید (یا یک آزمایشِ نویزِ مصنوعی)، اندازه بگیرید، چشمی قضاوت نکنید. یک تکنیکِ رایج: یک تصویرِ تمیز بردارید، نویزِ معلوم اضافه کنید، حذف کنید، و PSNR را با اصلِ تمیز بسنجید — چون «حقیقتِ زمینه» را دارید.

۲.۸ معضلِ حذفِ نویز

هر حذف‌کنندهٔ نویز، **حذفِ نویز** را در برابرِ **حفظِ جزئیات** معاوضه می‌کند. حذفِ خیلی کم ← نویز گامِ بعدی را می‌شکند؛ خیلی زیاد ← ارقام را پاک می‌کنید. ناهارِ مجانی وجود ندارد: نقطهٔ کاری را برای هدفِ خودتان (ارقامِ خوانا) انتخاب کنید. برای هدفِ پایین‌دستی حذفِ نویز کنید، اندازه‌گیری‌شده روی تصاویرِ سخت — نه برای زیباترین دیوارِ تخت.

۳.۸ بازسازی در برابرِ بهبود

بهبود (جلسهٔ ۲) تصویر را بهتر به‌نظر می‌رساند (ذهنی). **بازسازی** تلاش می‌کند با مدل‌کردنِ تخریب، اصل را بازیابی کند (عینی). رفعِ تاری (deblurring) هم بازسازی است: اگر تاری را بشناسید (تابعِ پخشِ نقطه، PSF)، می‌توانید تا حدی معکوسش کنید.

۴.۸ رفعِ تاری و PSF

تاری = کانولوشن با یک **تابعِ پخشِ نقطه** (PSF). رفعِ تاری = واهم‌گشت (deconvolution). معکوسِ ساده‌لوحانه نویز را به‌طورِ فاجعه‌بار تقویت می‌کند؛ روش‌های واقعی (Wiener، Richardson-Lucy) منظم‌سازی می‌کنند. تاریِ حرکتی/دفوکوس روی عکسِ کنتور اغلب بهتر است پرهیز شود (عکسِ ثابت) تا رفع شود. رفعِ تاریِ کامل وقتی اطلاعات واقعاً از دست رفته ناممکن است — پیش‌گیری از بازسازی بهتر است.

۹ حذفِ نویزِ زمانی و یادگیریِ عمیق

۱.۹ میانگین‌گیریِ چند فریم

اگر چند عکس از یک صحنهٔ ثابت دارید، آن‌ها را میانگین بگیرید: نویز حذف می‌شود، سیگنال می‌ماند. N فریم نویزِ گاوسی را با $\sqrt{N}$ کاهش می‌دهند — ارزان‌ترین و باکیفیت‌ترین حذف‌کنندهٔ نویز، بدونِ ازدست‌رفتنِ جزئیات. برای کنتوری که می‌توانید دوبار عکس بگیرید، این از هر فیلترِ تک‌تصویری بهتر است.

یادداشت

وقتی اکتساب را کنترل می‌کنید، میانگین‌گیریِ یک برستِ عکس بهترین حذفِ نویزی است که می‌توانید انجام دهید. این یک درسِ کلی است: گاهی بهترین راهِ حلِ یک مسئلهٔ پردازش، بهبودِ اکتساب است، نه پردازشِ سخت‌تر.

۲.۹ ریاضیِ میانگین‌گیریِ فریم‌ها

چرا میانگین‌گیریِ N فریم نویز را با $\sqrt{N}$ کاهش می‌دهد؟ فرض کنید هر فریم $g_i = f + n_i$ است که f سیگنالِ ثابت و n_i نویزِ مستقلِ میانگین‌صفر با انحرافِ معیارِ σ است. میانگین:

$$\bar{g} = \frac{۱}{N}\sum_{i=۱}^{N} g_i = f + \frac{۱}{N}\sum_{i=۱}^{N} n_i$$

جملهٔ سیگنال (f) بی‌تغییر می‌ماند، اما انحرافِ معیارِ جملهٔ نویز به $\sigma/\sqrt{N}$ کاهش می‌یابد (چون نویزها مستقل‌اند و تا حدی همدیگر را خنثی می‌کنند). پس با ۴ فریم، نویز نصف می‌شود؛ با ۱۰۰ فریم، ده برابر کمتر.

ریاضیات

انحرافِ معیارِ نویزِ میانگین‌گرفته‌شده: $\sigma_{\bar{g}} = \dfrac{\sigma}{\sqrt{N}}$. این پایهٔ ریاضیِ چرا «برستِ عکس» بهترین حذفِ نویز است.

۳.۹ نسبتِ سیگنال به نویز (SNR)

SNR می‌سنجد سیگنال چقدر قوی‌تر از نویز است. SNR بالا = تصویرِ تمیز؛ پایین = نویزی. هدفِ حذفِ نویز، بالابردنِ SNR است بدونِ آسیب به سیگنال. مفهومِ مرتبطی با PSNR است، اما SNR به خودِ تصویر (نه یک مرجع) اشاره دارد. در عمل، وقتی SNR خیلی پایین باشد (نورِ خیلی کم)، هیچ فیلتری معجزه نمی‌کند — اطلاعات از ابتدا نبوده. باز هم: کیفیتِ اکتساب مهم‌تر از هر پردازشِ بعدی است.

۴.۹ حذف‌کننده‌های یادگیریِ عمیق (پیش‌درآمد)

حذف‌کننده‌های مدرن، هایی‌اندCNN که روی جفت‌های (نویزی، تمیز) آموزش دیده‌اند — از روش‌های کلاسیک بهترند. اما به داده، محاسبه نیاز دارند و می‌توانند جزئیاتی را که وجود ندارد توهم کنند.

چند نکتهٔ مهم دربارهٔ حذف‌کننده‌های عمیق:

- **مزیت**: کیفیتِ چشمگیر، به‌ویژه روی نویزِ پیچیده و واقعی که مدلِ ریاضیِ ساده‌ای ندارد.
- **هزینه**: نیاز به دیتاستِ آموزشی، GPU، و زمانِ آموزش.
- **خطر**: **توهم** — شبکه ممکن است جزئیاتی بسازد که «قابل‌باور» اما غلط‌اند. برای یک کنتور، این فاجعه‌بار است: یک رقمِ ۳ ممکن است به ۸ تبدیل شود!
- **قابلیتِ تفسیر**: برخلافِ میانه (که دقیقاً می‌دانید چه می‌کند)، یک CNN جعبهٔ سیاه است.

هشدار / دام

برای کاربردهای حساس مثلِ خواندنِ کنتور، **توهمِ** حذف‌کننده‌های عمیق خطرِ جدی است. یک روشِ کلاسیکِ ساده که ممکن است کمی نویز باقی بگذارد، بهتر از یک شبکه‌ای است که با اطمینان رقمِ غلط می‌سازد. برای DocScan، کلاسیک (میانه/دوطرفه/NLM) معمولاً کافی و کاملاً قابلِ‌تفسیر است.

۱۰ کور در برابرِ غیرکور

حذفِ نویز/رفعِ تاری دو حالت دارد: **غیرکور** (non-blind) که در آن پارامترهای تخریب (مثلِ σ نویز یا PSF تاری) را می‌دانید، و **کور** (blind) که باید آن‌ها را هم تخمین بزنید. غیرکور آسان‌تر و دقیق‌تر است؛ کور واقعی‌تر اما سخت‌تر. در عمل، اغلب σ نویز را از یک ناحیهٔ تختِ تصویر تخمین می‌زنیم و مسئله را به غیرکور تبدیل می‌کنیم.

یادداشت

برای DocScan، معمولاً حالتِ کور داریم (نمی‌دانیم عکس چقدر نویزی است). یک راهبردِ عملی: چند سطحِ حذفِ نویز را امتحان کنید و آن را که بهترین باینریِ نهایی را می‌دهد انتخاب کنید — یعنی از هدفِ پایین‌دستی برای تنظیمِ پارامترِ نامعلوم استفاده کنید.

۱۱ این جلسه در پروژهٔ نهایی

در DocScan، حذفِ نویز زودهنگام در خطِ لوله می‌آید — پیش از بهبود (که نویز را تقویت می‌کرد) و پیش از آستانه‌گذاری (که نویز خرابش می‌کرد). اما نه خیلی تهاجمی: حذفِ بیش‌ازحد ارقامی را که لازم دارید پاک می‌کند.

جریانِ عملی برای یک عکسِ کنتورِ نویزی:

```
gray  = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)
den   = cv2.bilateralFilter(gray, 9, 60, 60)   # denoise, keep digit edges
# then: enhance (CLAHE) -> threshold (adaptive) -> morphology (Week 7)
```

یادداشت

مایلستونِ هفتهٔ ۴: برای عکس‌های نویزیِ کنتور، نشان دهید که حذفِ نویزِ درست، باینریِ نهایی (از جلسهٔ ۲) را تمیزتر می‌کند. اگر بدونِ حذفِ نویز آستانه بزنید، نویز به لکه‌های سیاه/سفیدِ فراوان تبدیل می‌شود که ارقام را غیرقابلِ‌خواندن می‌کند.

۱۲ جمع‌بندی

- تشخیصِ نویزِ گاوسی در برابرِ ضربه‌ای و نام‌بردنِ منشأِ فیزیکی.
- انتخابِ فیلترِ متناظر (میانه / گاوسی / دوطرفه / NLM).

- اندازه‌گیریِ بازسازی با PSNR/SSIM به‌جای قضاوتِ چشمی.
- استدلال دربارهٔ مبادلهٔ نویز-در-برابرِ-جزئیات برای خطِ لوله.

تمرین

تحویلیِ این هفته (پیش از جلسهٔ ۵): (۱) نویزِ گاوسی و نمک‌وفلفل به یک کنتورِ تمیز اضافه کنید (نویزِ معلوم = حقیقتِ زمینه). (۲) هرکدام را با ۳ فیلتر حذف کنید؛ PSNR را در برابرِ اصلِ تمیز حساب و جدول کنید. (۳) موردی نشان دهید که فیلترِ «اشتباه» شکست می‌خورد (گاوسی روی نمک‌وفلفل). (۴) DocScan: یک عکسِ نویزیِ واقعی را چنان حذفِ نویز کنید که باینریِ تطبیقی‌اش/Otsu تمیز شود.

نویز چطور هر گام را می‌شکند

گام	اثرِ نویز اگر حذف نشود
آستانه‌گذاری	لکه‌های سیاه/سفیدِ فراوان؛ ارقامِ شکسته
تشخیصِ لبه (ج۵)	لبه‌های کاذبِ بی‌شمار
یافتنِ کانتور (ج۹)	کانتورهای ریزِ نویزی؛ شمارشِ غلط
تطبیقِ ویژگی (ج۱۰)	نقاطِ کلیدیِ ناپایدار

این جدول توضیح می‌دهد چرا حذفِ نویزِ زودهنگام این‌قدر مهم است: نویز در گام‌های بعدی تکثیر می‌شود و رفعش سخت‌تر می‌گردد.

چک‌لیستِ دام‌های این هفته

- گاوسی روی نمک‌وفلفل (پخشِ لکه‌ها به‌جای حذف) — به‌جایش میانه.
- حذفِ نویزِ بیش‌ازحد (پاک‌شدنِ ارقام) — کوچک‌ترین فیلترِ کافی.
- بهبود پیش از حذفِ نویز (تقویتِ نویز) — اول حذفِ نویز.
- قضاوتِ چشمیِ کیفیت — با PSNR/SSIM یا اثرِ پایین‌دستی اندازه بگیرید.
- نادیده‌گرفتنِ نویزِ دوره‌ای در حوزهٔ مکانی — آن را در فرکانس (ج۶) حذف کنید.

واژه‌نامهٔ کوتاه

اصطلاح	معنی
Gaussian noise	نویزِ جمعیِ میانگین‌صفر (حسگر)
Salt-and-pepper	نویزِ ضربه‌ای (پیکسل‌های ۰/۲۵۵)
Median filter	میانهٔ همسایگی؛ مقاوم به پرت‌داده
Bilateral / NLM	حذفِ نویزِ حفظ‌کنندهٔ لبه
PSNR / SSIM	معیارهای کیفیتِ بازسازی
PSF	تابعِ پخشِ نقطه (مدلِ تاری)

فیلتر را با نویز تطبیق بده. میانه برای لکه‌ها، میانگین برای دانه، دوطرفه برای حفظِ لبه.